

PROGETTO FINALE

Classificazione dei Generi Musicali

Componenti del gruppo

- Antonella Franza
 - Giuseppe Cristiano
 - Laura Novellino
 - Luana Uda
-

Obiettivo del progetto

L'obiettivo del progetto è sviluppare un modello di Machine Learning in grado di classificare automaticamente il genere musicale di un brano utilizzando le caratteristiche audio presenti nel dataset.

Il dataset contiene oltre 50.000 canzoni appartenenti a diversi generi musicali e include informazioni quali danceability, energy, acousticness, tempo, loudness, popularity e altre caratteristiche audio utili alla classificazione.

Il progetto prevede le seguenti fasi:

1. Analisi esplorativa dei dati.
 2. Preprocessing e preparazione del dataset.
 3. Addestramento e validazione dei modelli di classificazione.
 4. Visualizzazione e interpretazione dei risultati.
 5. Ottimizzazione risultati con Optuna
 6. Visualizzazione grafica dei vari output tramite grafici
 7. Interfaccia grafica
-

Suddivisione dei compiti

Parte 1 – Caricamento dei dati e Analisi Esplorativa

Responsabile: Antonella

Attività assegnate

- Importazione del dataset. ✓
 - Suddivisione del dataset in Training Set e Test Set. ✓
 - Individuazione di eventuali valori mancanti. ✓
 - Analisi statistica descrittiva. ✓
 - Studio della distribuzione dei generi musicali. ✓
 - Individuazione delle principali correlazioni tra le variabili. ✓
 - Ottimizzazione accuracy con optuna ✓
 - Ottimizzazione interfaccia grafica ✓
 - Preparazione slide ✓
-

Parte 2 – Preprocessing e Addestramento del Modello

Responsabile: Giuseppe

Attività assegnate

- Pulizia dei dati. ✓
 - Gestione dei valori mancanti. ✓
 - Analisi della struttura del dataset. ✓
 - Rimozione delle colonne non utili alla classificazione. ✓
 - Codifica della variabile target (genere musicale). ✓
 - Standardizzazione delle feature numeriche. ✓
 - Addestramento dei modelli di classificazione. ✓
 - Gestione Grafici ✓
 - Ottimizzazione accuracy con optuna ✓
 - Ottimizzazione interfaccia grafica ✓
 - Preparazione slide ✓
-

Parte 3 – Validazione del Modello

Responsabile: Laura

Attività assegnate

- Valutazione delle prestazioni dei modelli. ✓
- Calcolo delle metriche di classificazione: ✓

- Accuracy
- Precision
- Recall
- F1- score
- Analisi delle Confusion Matrix. ✓
- Confronto delle prestazioni tra i modelli testati. ✓
- Individuazione del modello migliore. ✓
- Gestione Grafici ✓
- Gestione Interfaccia Grafica ✓
- Ottimizzazione accuracy con optuna ✓
- Preparazione slide ✓

Parte 4 – Visualizzazione Grafica dei Risultati

Responsabile: Luana

Attività assegnate

- Creazione dei grafici esplorativi. ✓
- Visualizzazione della distribuzione dei generi musicali. ✓
- Realizzazione della heatmap delle correlazioni. ✓
- Grafici delle principali feature audio. ✓
- Visualizzazione delle performance dei modelli. ✓
- Realizzazione delle confusion matrix. ✓
- Grafico comparativo delle metriche dei modelli. ✓
- Grafico dell'importanza delle feature del modello finale. ✓
- Ottimizzazione accuracy con optuna ✓
- Ottimizzazione interfaccia grafica ✓
- Preparazione slide ✓

Registro delle attività

Data	Componente	Attività svolta
03/06	Giuseppe	pulizia e gestione dataset (in quanto molto grande), analisi del dataset rimozione di colonne inutili e dei valori null. Grafico 1: Distribuzione generi musicali. Grafico 7: Distribuzione caratteristiche audio.

03/06	Laura	supervisione, gestione documentazione, kanban board, gestione GitHub Grafico 2: Popularity.
03/06	Luana	gestione grafici come output per eventuali curiosità e descrizione delle varie statistiche Grafico 3: Energy. Grafico 4: Danceability. Grafico 6: Heat Map
03/06	Antonella	gestione iniziale del codice con creazione del data frame e analisi delle statistiche Grafico 5: Acousticness .
04/06	Gruppo	Gestione outliers e correzione scala dati delle seguenti colonne: duration_ms, loudness ,key, mode, drop di arthist_name, track_name. Rifatto alcuni grafici con le variabili aggiornate. Preparazione al machine learning completata e corretto tutti i vari errori a livello logico.
04/06	Antonella e Giuseppe	applicazione della PCA per ridurre il numero di variabili ed eliminare la ridondanza informativa (es. energy e loudness) ma si è presentato un calo dell'accuracy rispetto ai dati originali
04/06	Luana e Laura	Applicazione del Clustering 3D, ma anche in questo caso si è verificato un fallimento poichè si è ripresentato un peggioramento dell'accuracy
04/06	Gruppo	Stress Test: esecuzione di svariati test per forzare l'ottimizzazione dell'accuracy, è stata creata e applicata una scala dei pesi personalizzata per dare una maggiore importanza alle variabili per ogni genere, sono stati testati anche modelli come Random Forest e Light GBM con e senza pesi, ma anche in questo caso l'accuracy migliore è stata del 57.78%. L'ultimo try è andato decisamente bene e abbiamo superato il 75% di accuracy
05/06	Antonella	Gestione Modello Light Gbm

05/06	Laura	Gestione interfaccia grafica
05/06	Luana	Gestione Modello Decision Tree Grafico Confusion Matrix
05/06	Giuseppe	Gestione Modello Random Forest
05/06	Gruppo	Ottimizzazione con Optuna dell' accuracy Ottimizzazione interfaccia grafica Preparazione slide e presentazione

Risultati finali

Modello selezionato

Random Forest

Decision Tree

Light Gbm

Accuratezza finale

Ottimizzata con Optuna

Random Forest 78,01

Decision Tree 77,42

Light Gbm 77,97

Considerazioni finali

Questo progetto dimostra che il Machine Learning può riconoscere automaticamente il genere di una canzone ascoltando solo i suoi dati tecnici (come volume, ritmo e acusticità).

I punti chiave del lavoro sono stati:

1. Confronto tra modelli: Sono stati messi alla prova diversi modelli (Decision Tree, Random Forest e LightGBM) per trovare il più intelligente e preciso nel fare le previsioni.

2. Controllo degli errori: Tramite precisi test matematici e tabelle grafiche, sono stati trovati e corretti i punti in cui il computer confondeva un genere con un altro.

Il tocco finale con Optuna: Questo strumento automatico ha cercato e trovato le impostazioni perfette per spremere il massimo dell'accuratezza possibile dai programmi usati.

Conclusione: Il successo del progetto conferma che per avere un'intelligenza artificiale affidabile non serve solo un buon algoritmo, ma è fondamentale pulire bene i dati iniziali, eliminare il rumore e regolare con precisione millimetrica i parametri di addestramento

Chronology

3/06/2026 10.00 - 11.00 : Scelta tema principale e dataset

3/06/2026 11.00 - 12.00 : Suddivisione ruoli e creazione repository GitHub

3/06/2026 12.00 - 13.00 : Allineamento documentazione e iniziale gestione Kanban Board

3/06/2026 14.00 - 15.00 : Presentazione iniziale, gestione iniziale dataframe con statistiche e grafici iniziali

3/06/2026 15.00 - 17.00 : Sviluppo 7 grafici con descrizione delle varie casistiche

3/06/2026 17.00 - 18.00 : Pausa + pulizia codice e commenti per chiarire alcuni punti

4/06/2026 09.00 - 11.00 : Presentazione + gestione outliers o errori nel dataset

4/06/2026 11.00 - 18.00: Preparazione dei vari dati per il machine learning + stress test

5/06/2026 10.00 - 13.00: Creazione, preparazione e implementazione dell'interfaccia grafica

5/06/2026 14.00 - 16.00: Ottimizzazione interfaccia grafica e preparazione per la presentazione